

# NoSQL y Big Data

# NoSQL

---

Se puede decir que la aparición del término NoSQL fue con la llegada de la web 2.0 con aplicaciones como Facebook, Twitter o Youtube, cualquier usuario podía subir contenido, provocando así un crecimiento en las necesidades de almacenamiento.

---

Las bases de datos NoSQL tienen estructuras que permiten almacenar información en aquellas situaciones en las que las bases de datos relacionales generan ciertos problemas como escalabilidad y rendimiento, en donde se dan cita miles de usuarios concurrentes y con millones de consultas diarias

---

Las bases de datos NoSQL son sistemas de almacenamiento de información que no cumplen con un esquema entidad relación. Tampoco utilizan una estructura de datos en forma de tabla donde se van almacenando los datos, sino que hacen uso de otros formatos, como clave–valor, mapeo de columnas o grafos.

# NotOnlySQL

---

NoSQL, Not Only SQL ("no sólo SQL") es una amplia clase de sistemas de gestión de bases de datos que difieren del modelo clásico del sistema de gestión de bases de datos relacionales (RDBMS) en aspectos importantes, en donde el más destacado es que no usan SQL como el principal lenguaje de consultas.

---

Los datos almacenados no requieren estructuras fijas como tablas, normalmente no soportan operaciones de reunión (join), ni garantizan completamente las propiedades ACID (atomicidad, consistencia, aislamiento y durabilidad) transaccionales, y habitualmente escalan bien horizontalmente.

---

Las bases de datos NoSQL están altamente optimizadas para las operaciones recuperar y agregar, y normalmente no ofrecen mucho más que la funcionalidad de almacenar los registros

# Diferencias con SABDR

**No utilizan SQL como lenguaje de consultas.** La mayoría de las bases de datos NoSQL evitan utilizar este tipo de lenguaje o lo utilizan como un lenguaje de apoyo. Por poner algunos ejemplos, Cassandra utiliza el lenguaje CQL, MongoDB utiliza JSON o BigTable hace uso de GQL.

**No utilizan estructuras fijas como tablas para el almacenamiento de los datos.** Permiten hacer uso de otros tipos de modelos de almacenamiento de información como sistemas de clave-valor, objetos o grafos.

**No suelen permitir operaciones JOIN.** Al disponer de un volumen de datos tan extremadamente grande suele resultar deseable evitar las reuniones. Esto se debe a que, cuando la operación no es la búsqueda de una clave, la sobrecarga puede llegar a ser muy costosa. Las soluciones más directas consisten en desnormalizar los datos, o bien realizar el JOIN mediante software, en la capa de aplicación.

**Arquitectura distribuida.** Las bases de datos relacionales suelen estar centralizadas en una única máquina o bien en una estructura maestro-esclavo; sin embargo en los casos NoSQL la información puede estar compartida en varias máquinas mediante mecanismos de tablas Hash distribuidas.

# Ventajas de NoSQL

Se ejecutan en máquinas con pocos recursos: Estos sistemas, a diferencia de los sistemas basados en SQL, no requieren de mucha computación, por lo que se pueden montar en máquinas de costo reducido.

Escalabilidad horizontal: Para mejorar el rendimiento de estos sistemas, se añaden más nodos, con la única operación de indicar al sistema cuáles son los nodos que están disponibles.

Pueden manejar gran cantidad de datos: Esto es debido a que utiliza una estructura distribuida, en muchos casos mediante tablas Hash.

# THE FUTURE OF THE DATABASE

## 1960s

First Computerized Database Models

Hierarchical Model (IMS)

Network Model (CODASYL)

## 1970s

The Dawn of the Database

- The relational model and its language SQL emerges
- The disruptive model causes the demise of other models

1970 E.F. Codd Writes a Paper on the Relational Database Model

Single Instance Relational Database

System R by IBM (SQL)  
Ingres (QUEL)

Entity Relational Database

ORACLE  
1st commercially available RDBMS

IBM DB2

SAP Sybase  
Informix

Object Oriented Database

Distributed SQL Data Warehouse

Teradata

Dawn of the Internet

## 1990s

Technology Shifts

- Data explodes with the Internet age
- Single server SQL databases run into resource problems
- Business Intelligence and Analytics move out of transactional database

BUSINESS INTELLIGENCE

ANALYTICS

Application Layer

New Distributed SQL Data Warehouse

## 2000s

## 2000s

New Players Emerge

- Data variety, velocity and volume increase
- New analytics SQL databases are introduced
- NoSQL databases fill the gap for processing unstructured data
- Hadoop gains traction for analyzing petabytes of data

## Today

Databases Adapt and Evolve

- Businesses require real-time analytics on operational data
- Scale-up SQL proves too costly, but scale-out removes resource constraint
- Scale-out provides real time analytics with high volume transactions
- Google and Clustrix are pioneers in this space

The Future  
Businesses Advance with Database Innovations

- Single node SQL gets replaced by scale-out SQL
- Data warehouse type analytics will become available in real-time database
- Businesses gain a significant edge and increased agility

Winning Database Platforms

NOSQL DATABASE

DISTRIBUTED SQL

HADOOP



Google BigTable  
CouchDB  
MongoDB  
Cassandra  
Redis



Netezza  
Microsoft  
Aster  
Oracle  
SAP  
IBM  
Vertica



SQL HIVE

REAL-TIME ANALYTICS

ALL ANALYTICS?

+ COLUMNAR  
REPLACED?

Clustrix  
NuoDB  
VoltDB  
Google Spanner

+MASSIVELY PARALLEL PROCESSING  
MPP  
Clustrix adds MPP  
SAP HANA In-memory

Oracle In-memory option



# Introduction of New Database Technologies 1994–2014

Arranged by date of first public release (source: Wikipedia)

~~dead~~ • closed-source • open-source

Server Databases

MySQL

PostgreSQL

MarkLogic

Netezza

Hadoop

CouchDB

Greenplum

Vertica

Neo4J

SimpleDB

Drizzle

Cassandra

Riak

Voldemort

Hypertable

MariaDB

Redis

MongoDB

RethinkDB

OrientDB

Xeround

FlockDB

RavenDB

Clustrix

Membase

Translattice

NimbusDB/NuoDB

Citrusleaf/Aerospike

DynamoDB

Datomic

MemSQL

HyperDex

TokuDB

GenieDB

FoundationDB

Apollo

Cayley

1994

1995

2000

2003

2005

2006

2007

2008

2009

2010

2011

2012

2013

2014

Mobile Databases

SQLite

Realm

# Fiabilidad

Una aplicación de uso intensivo de datos debe ser confiable, escalable y mantenible. Incluso en el caso de un incremento de la carga de trabajo.

La fiabilidad es una característica importante de las aplicaciones de uso intensivo de datos.

La fiabilidad es cuando el sistema debe continuar funcionando correctamente incluso frente a la adversidad.

La aplicación realiza las funciones esperadas por el usuario.

- Puede tolerar errores de usuario o la ejecución de software de maneras inesperadas.
- Su rendimiento es lo suficientemente bueno para el caso de uso requerido bajo cargas esperadas y volumen de datos.
- El sistema evita cualquier acceso no autorizado.
- En el caso de la escalabilidad a medida que un sistema crece en volumen de datos, volumen de tráfico o complejidad, deberían existir formas razonables de hacer frente a ese crecimiento.
- La escalabilidad es la capacidad de un sistema para hacer frente al aumento de la carga.



# Escalabilidad

- Discutir la escalabilidad significa considerar preguntas como, si el sistema crece de una manera particular:
- ¿Cuáles son nuestras opciones para hacer frente al crecimiento?
- ¿Cómo podemos agregar recursos informáticos para manejar la carga adicional?
- Una aplicación intensiva de datos debería funcionar bien en caso de aumento de la carga de trabajo.
- La carga de trabajo depende de la arquitectura del sistema.
  - Por ejemplo, el número de solicitudes por segundos a nuestro servidor web, la relación entre lecturas y escrituras en una base de datos, el número de usuarios activos simultáneamente en una sala de chat o la tasa de visitas en un caché o algo más.

# Mantenibilidad

- Una aplicación intensiva de datos debe ser mantenible.
- Con el tiempo, muchas personas diferentes trabajarán en el sistema, la ingeniería y las operaciones, mantendrán el comportamiento actual y adaptarán el sistema a nuevos casos de uso, y todos deberían poder trabajar en él de manera productiva.
- Existen tres principios de diseño de sistemas de software que les ayudan a ser mantenidos.
  - **Operabilidad**, es cuando un equipo de operaciones hace más fácil mantener el sistema funcionando sin problemas.
  - La **simplicidad** facilita a los nuevos ingenieros la comprensión del sistema al eliminar la mayor complejidad posible del sistema.
  - **Evolucionabilidad**, facilita realizar cambios en el sistema en el futuro, adaptándolo a casos de uso imprevistos a medida que cambian los requisitos.

# El teorema CAP

- El teorema CAP o teorema Brewer, dice que en sistemas distribuidos es imposible garantizar a la vez: la consistencia, la disponibilidad y la tolerancia a particiones (Consistency-Availability-Partition Tolerance):
  - **Consistencia:** al realizar una consulta o inserción siempre se tiene que recibir la misma información, con independencia del nodo o servidor que procese la petición.
  - **Disponibilidad:** que todos los clientes puedan leer y escribir, aunque se haya caído uno de los nodos.
  - **Tolerancia a particiones:** a veces traducido como tolerancia a fallos. Es una traducción que no me gusta, ya que se confunde con el punto anterior. Los sistemas distribuidos pueden estar divididos en particiones (generalmente de forma geográfica). Así que esta condición implica, que el sistema tiene que seguir funcionando aunque existan fallos o caídas parciales que dividan el sistema.

## Clasificación de cada base de datos NoSQL según el teorema CAP

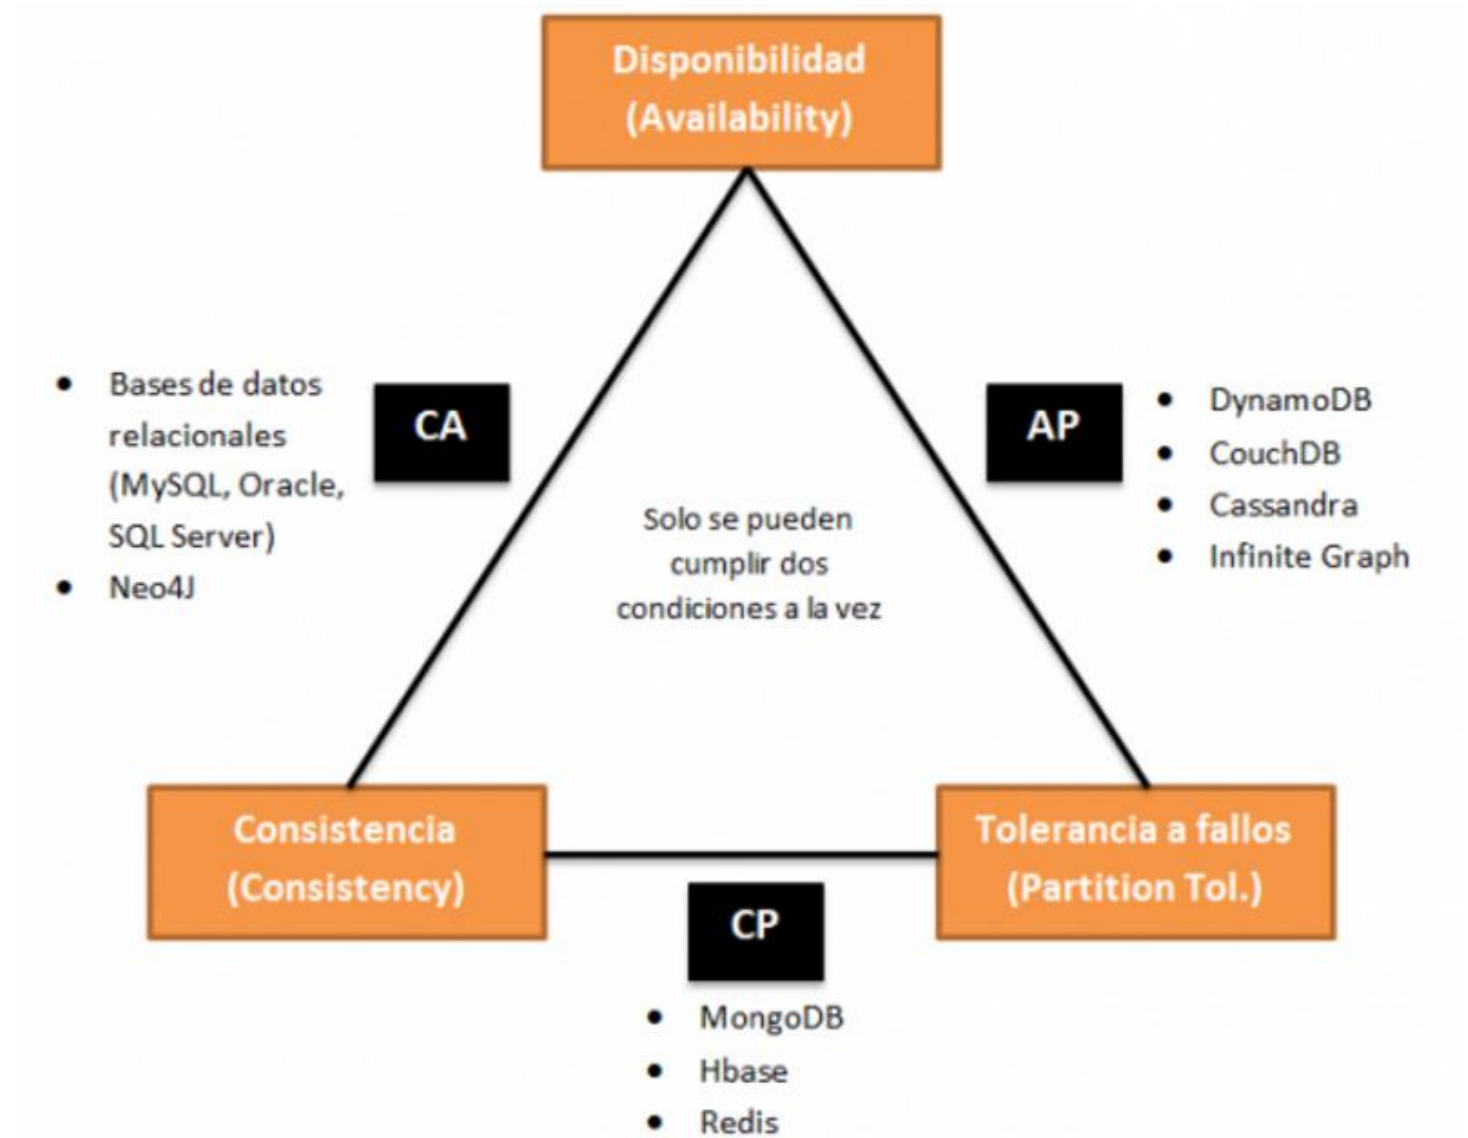
Para ser escalables y distribuidas, las bases de datos NoSQL, siguen distintos métodos, por lo que **no todas cumplen los mismos puntos del teorema CAP.**

En la imagen que encabeza el artículo, podemos ver cómo se reparten algunas de las bases de datos según las condiciones que cumplen del teorema CAP.

- **AP:** garantizan disponibilidad y tolerancia a particiones, pero no la consistencia, al menos de forma total. Algunas de ellas consiguen una consistencia parcial a través de la replicación y la verificación.
- **CP:** garantizan consistencia y tolerancia a particiones. Para lograr la consistencia y replicar los datos a través de los nodos, sacrifican la disponibilidad.
- **CA:** garantizan consistencia y disponibilidad, pero tienen problemas con la tolerancia a particiones. Este problema lo suelen gestionar replicando los datos.

# Ejemplos

---




## SQL Database

### Relational




### Analytical (OLAP)




## NoSQL Database


### Column-Family




### Graph



### Document



### Key-Value





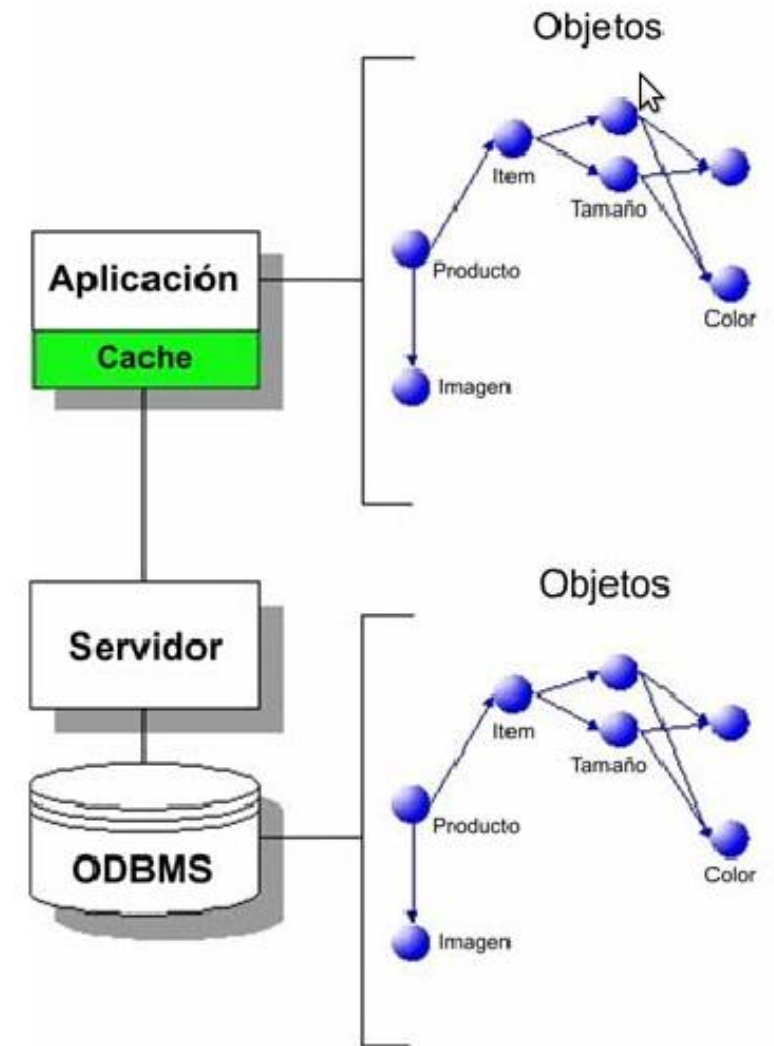
# Clasificación de Bases de datos recientes

---

- Se pueden identificar 4 categorías diferentes, y aunque todas ellas comparten rasgos comunes, cada una se adapta a un uso particular:
  - **Orientadas a documentos.**- son las más versátiles, gestionan datos semi-estructurados o documentos que son almacenados en algún formato estándar como puede ser XML, JSON o BSON. Ejemplos: MongoDB (utilizada por Foursquare o eBay), CouchDB, Couchbase Server, MarkLogic.
  - **Orientadas a columnas.**- pensadas para realizar consultas y agregaciones sobre grandes cantidades de datos, funcionan de forma parecida a las bases de datos relacionales, pero almacenando columnas de datos en lugar de registros. Ejemplos: Accumulo, Cassandra, HBase (mantenida por Hadoop; utilizada por Facebook, Twitter o Yahoo), Apache Flink
  - **De clave-valor.**- las más simples de entender, guardan tuplas clave-valor. Ejemplos: Aerospike, Redis, Riak, DynamoDB, Berkeley DB
  - **En grafo.**- basadas en la teoría de grafos, utilizan nodos y aristas para representar los datos almacenados, y son muy útiles para guardar información en modelos con muchas relaciones, como redes y conexiones sociales. Ejemplos: InfiniteGraph, Neo4j (utilizada en Infojobs)
  - **Multimodelo.**- presentan una combinación de dos o más tipos de almacenamiento. Ejemplos ArangoDB, OpenLink Virtuoso, OrientDB, Oracle NoSQL
- <http://nosql-database.org/>
- <https://bigdata-madesimple.com/a-deep-dive-into-nosql-a-complete-list-of-nosql-databases/>

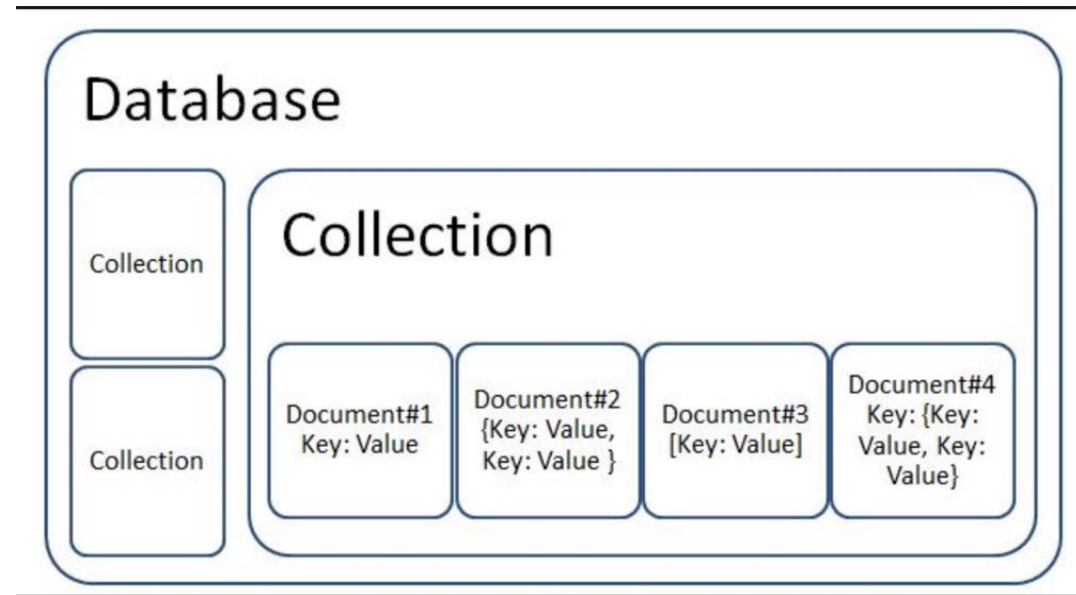
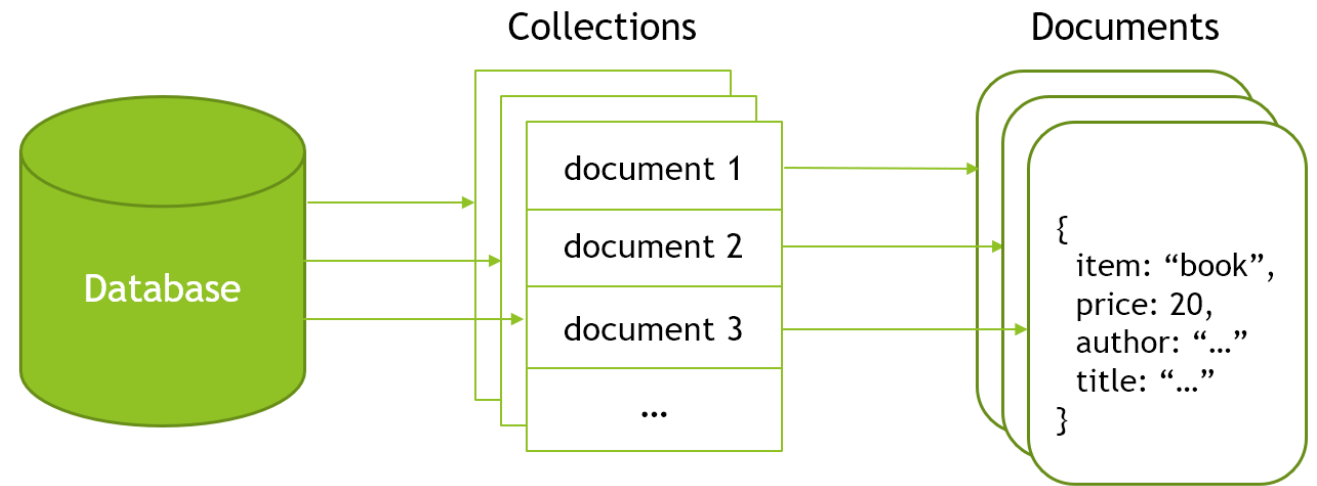
# Bases de datos orientadas a objetos

- En este tipo, la información se representa mediante objetos, de la misma forma que son representados en los lenguajes de programación orientada a objetos (POO) como ocurre en JAVA, C# o Visual Basic .NET.
- Pueden representar relaciones jerárquicas (generalización/ especialización), no se basan en claves primarias sino en OID (identificadores únicos de objetos calculados por la base de datos), y las relaciones son a través de apuntadores a objetos
- Algunos ejemplos de este tipo de bases de datos son Versant, Objectivity/DB, Zope, Gemstone y Db4o.



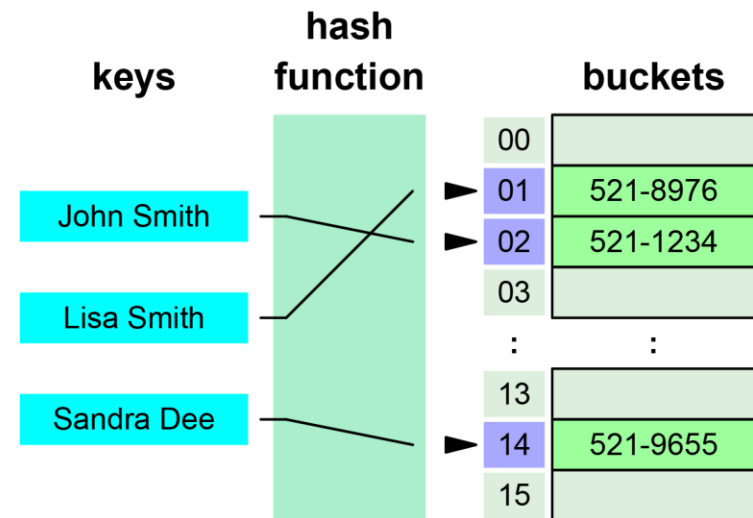
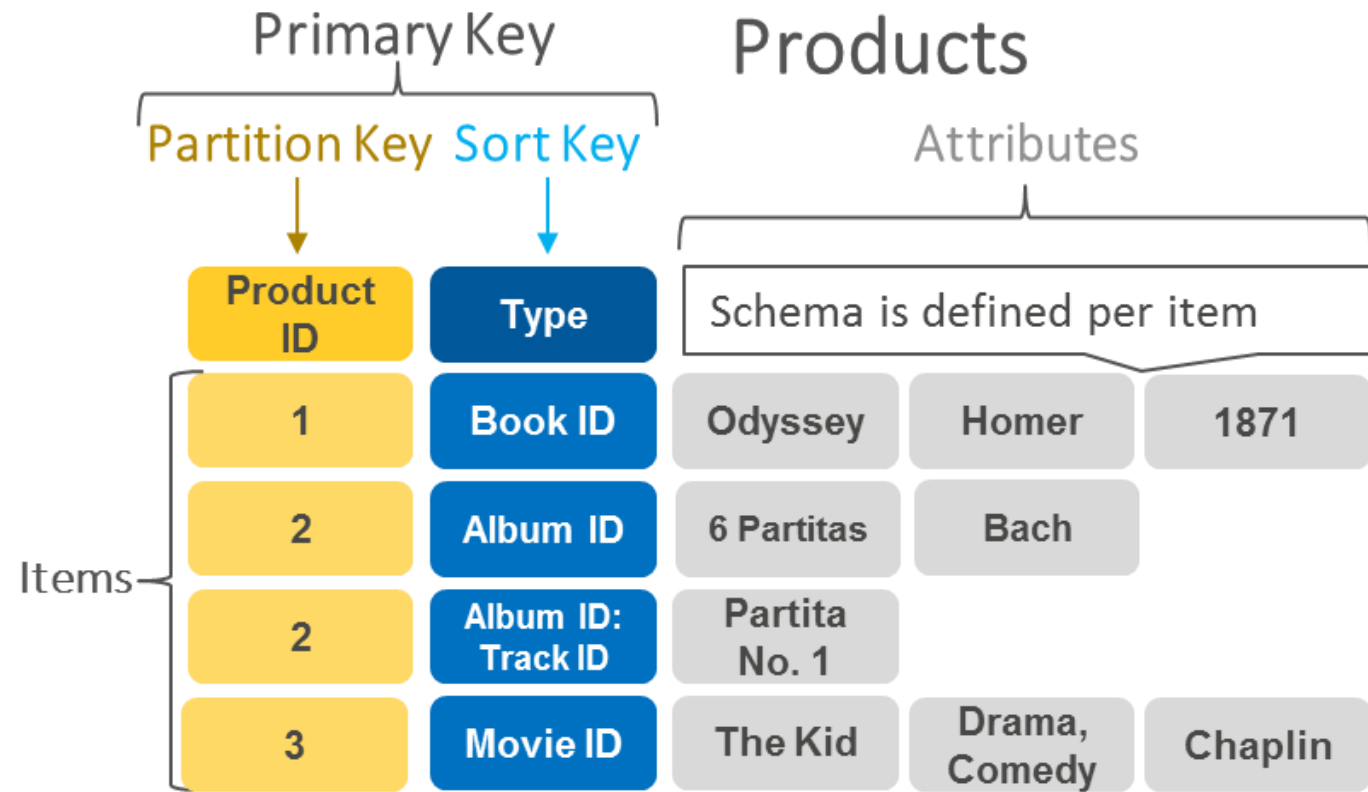
# Bases de datos documentales

- Este tipo almacena la información como un documento, generalmente utilizando para ello una estructura simple como JSON o XML y donde se utiliza una clave única para cada registro. Este tipo de implementación permite, además de realizar búsquedas por clave-valor, realizar consultas más avanzadas sobre el contenido del documento.
- Son las bases de datos NoSQL más versátiles. Se pueden utilizar en gran cantidad de proyectos, incluyendo muchos que tradicionalmente funcionarían sobre bases de datos relacionales.
- Algunos ejemplos de este tipo son MongoDB o CouchDB.



# Bases de datos clave – valor

- Son el modelo de base de datos NoSQL más popular, además de ser la más sencilla en cuanto a funcionalidad. En este tipo de sistema, cada elemento está identificado por una llave única, lo que permite la recuperación de la información de forma muy rápida, información que habitualmente está almacenada como un objeto binario (BLOB). Se caracterizan por ser muy eficientes tanto para las lecturas como para las escrituras.
- Su API es bastante simple y no es más que una variación de 3 operaciones: Put, Get, Delete.
- Su limitante está en que no permiten realmente un modelo de datos, todo lo que guardan es un valor binario.
- Algunos ejemplos de este tipo son Cassandra, BigTable o HBase.



# Bases de datos columnares

- Como su nombre lo indica, guardan los datos en columnas en lugar de renglones. Se gana mucha velocidad en lecturas, ya que si se quiere consultar un número reducido de columnas, es muy rápido hacerlo.
- Por otro lado, este paradigma no es muy eficiente para realizar escrituras. Por ello este tipo de soluciones es usado en aplicaciones con un índice bajo de escrituras pero muchas lecturas.
- Típicamente se usan en ambientes de Data Warehouses y sistemas de Business Intelligence, donde además resultan ideales para calcular datos agregados.

Row-oriented

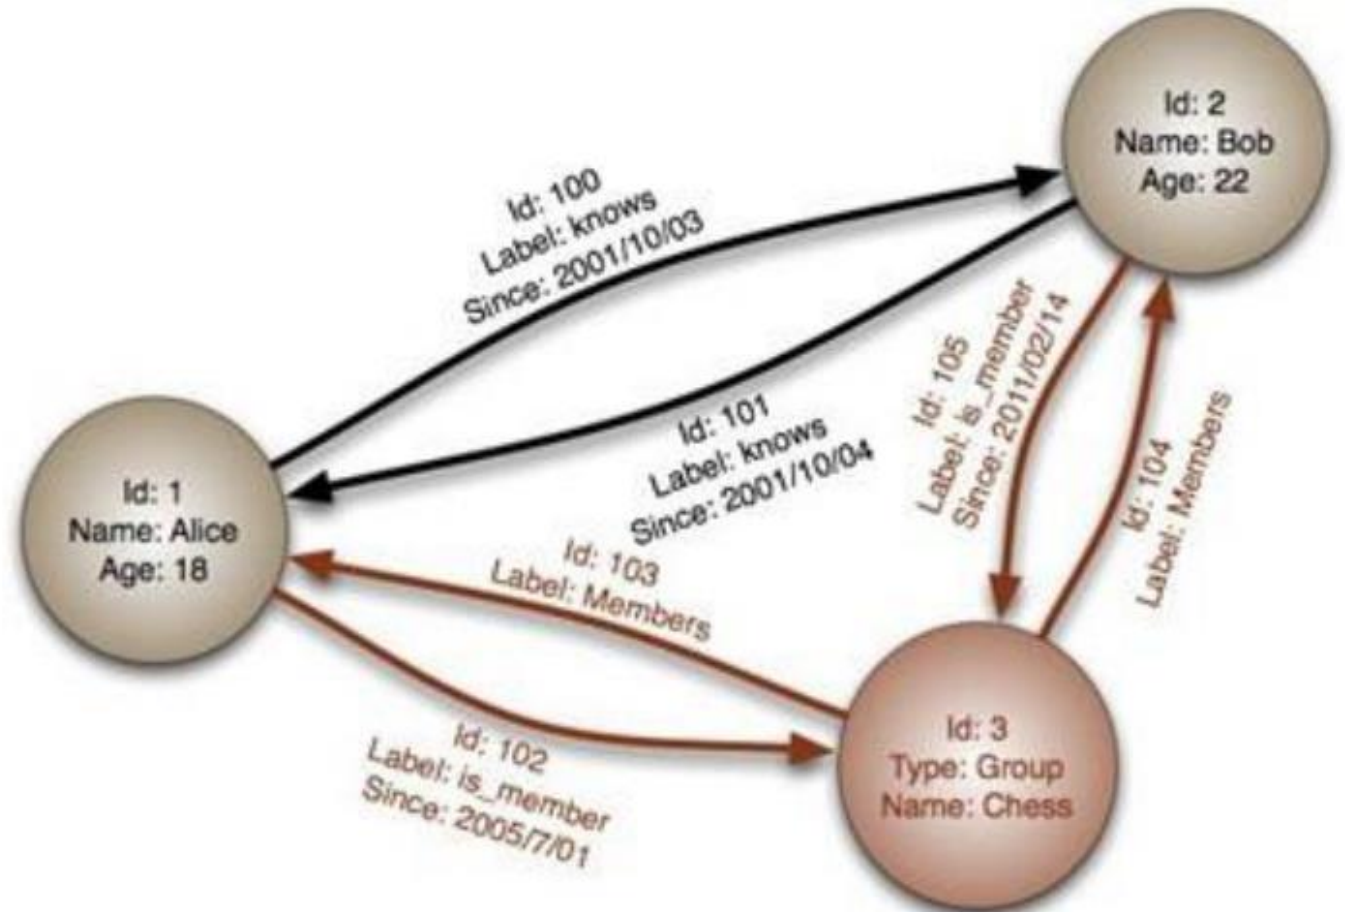
ID	Name	Grade	GPA
001	John	Senior	4.00
002	Karen	Freshman	3.67
003	Bill	Junior	3.33

Column-oriented

Name	ID	Grade	ID	GPA	ID
John	001	Senior	001	4.00	001
Karen	002	Freshman	002	3.67	002
Bill	003	Junior	003	3.33	003

# Bases de datos en grafo

- En este tipo de bases de datos, la información se representa como nodos de un grafo y sus relaciones con las aristas del mismo, de manera que se puede hacer uso de la teoría de grafos para recorrerla. Para sacar el máximo rendimiento a este tipo de bases de datos, su estructura debe estar totalmente normalizada, de forma que cada tabla tenga una sola columna y cada relación dos.
- Este tipo de bases de datos ofrece una navegación más eficiente entre relaciones que en un modelo relacional.
- Algunos ejemplos de este tipo son Neo4j, InfoGrid o Virtuoso





## Desventajas

---

No están lo suficientemente maduros para algunas empresas

---

Limitaciones de Inteligencia de Negocios

---

La falta de experiencia

---

Problemas de compatibilidad

# Big Data

---

Big Data tiene como objetivo resolver problemas antiguos y nuevos de manera más eficiente pero aplicado a extensos volúmenes de datos no usados hasta el momento

---

Genera valor a un negocio a partir del almacenamiento y procesamiento de cantidades muy grandes de información digital que no puede ser analizada con técnicas tradicionales de computación

# 2020 *This Is What Happens In An Internet Minute*



<https://bornintelligence.com/what-happens-in-one-internet-minute/>

# Las tres 'v' del Big Data

**Volumen:** Se considera un volumen grande a partir de Petabytes (1.000.000 GB)

**Velocidad:** Frecuencia a la que se genera los datos / Tiempo de análisis de los datos

**Variedad:** Datos estructurados, semi-estructurados, no estructurados  
¿Otras Vs?: ¿Veracidad? ¿Valor?

# El valor de los datos

El uso intensivo de los datos ha pasado a ser el petróleo de muchas compañías

El nuevo enfoque es almacenar cualquier tipo de dato, por irrelevante que pueda parecer, para su posterior análisis

- Clicks de ratón en la página web de mi negocio
- Vibración del motor del coche
- Movimiento del acelerómetro del smartphone

Permite crear modelos para responder preguntas complejas, mostrar percepciones contraintuitivas y aprender resultados únicos

# El valor de los datos

## AUTOMOTIVE

Auto sensors  
reporting  
location,  
problems



## COMMUNICATIONS

Location-based  
advertising



## CONSUMER PACKAGED GOODS

Sentiment analysis  
of what's hot,  
problems




## FINANCIAL SERVICES

Risk & portfolio analysis  
New products



## EDUCATION & RESEARCH

Experiment  
sensor analysis



## HIGH TECHNOLOGY / INDUSTRIAL MFG.

Mfg quality  
Warranty analysis



## LIFE SCIENCES

Clinical trials  
Genomics



## MEDIA/ ENTERTAINMENT

Viewers / advertising  
effectiveness



## ON-LINE SERVICES / SOCIAL MEDIA

People & career  
matching  
Web-site  
optimization



## HEALTH CARE

Patient sensors,  
monitoring, EHRs  
Quality of care



## OIL & GAS

Drilling  
exploration  
sensor analysis



## RETAIL

Consumer  
sentiment  
Optimized  
marketing



## TRAVEL & TRANSPORTATION

Sensor analysis for  
optimal traffic flows  
Customer sentiment



## UTILITIES

Smart Meter  
analysis for  
network  
capacity,



## LAW ENFORCEMENT & DEFENSE

Threat analysis -  
social media  
monitoring, photo  
analysis



**Challenged by: Data Volume, Velocity, Variety**



# Ejemplo de uso de Big Data

---

- **Amazon.com**

- Inicialmente contaba con críticos (humanos) para aconsejar a sus clientes sobre qué libros comprar
- Aunque funcionaba bien, la siguiente idea fue *personalizar* las recomendaciones en base a anteriores compras, libros por los que el cliente navega en la página, libros similares, etc.
- Las ventas se dispararon mejorando de manera drástica la técnica de las críticas
- Actualmente ofrece conjunto de datos públicos para Big Data


# Componentes de una plataforma Big Data

Las organizaciones han atacado esta problemática desde diferentes ángulos. Todas esas montañas de información han generado un costo potencial al no descubrir el gran valor asociado. Desde luego, el ángulo correcto que actualmente tiene el liderazgo en términos de popularidad para analizar enormes cantidades de información es la plataforma de código abierto Hadoop.

Hadoop está inspirado en el proyecto de Google File System(GFS) y en el paradigma de programación MapReduce, el cual consiste en dividir en dos tareas (mapper – reducer) para manipular los datos distribuidos a nodos de un clúster logrando un alto paralelismo en el procesamiento. Hadoop está compuesto de tres piezas: Hadoop Distributed File System (HDFS), Hadoop MapReduce y Hadoop Common.


# Hadoop

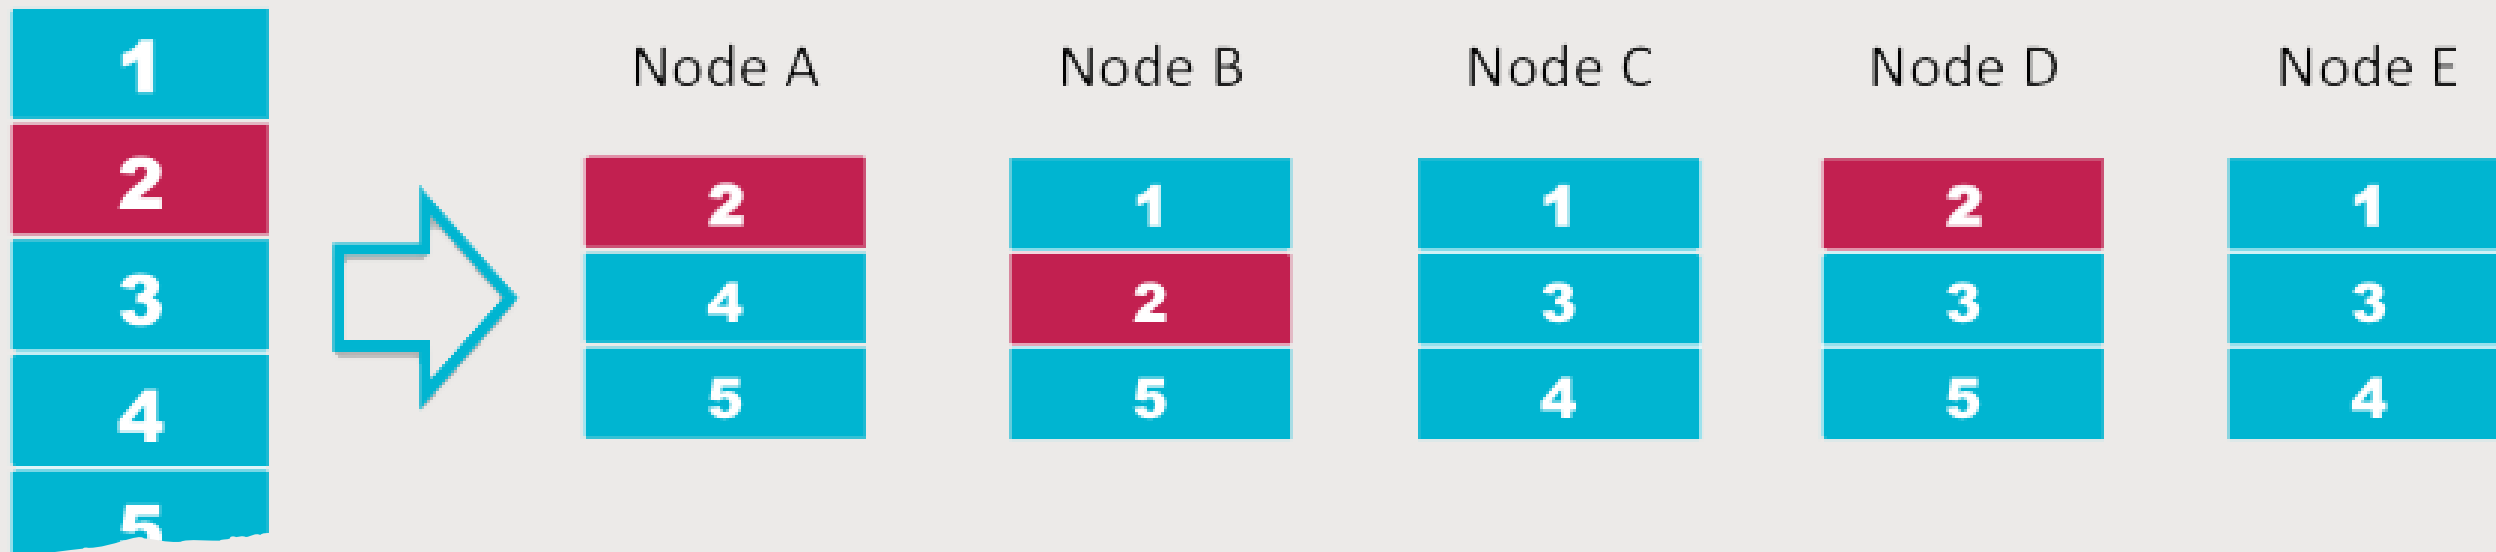
- La idea de contar con un gran número de nodos y cada uno con posibilidad de fallas, significa que en todo momento algún componente siempre no será funcional.
- Por lo tanto, la detección de fallas y rápida recuperación automática de un sistema distribuido debe ser un objetivo central de la arquitectura de HDFS



# Hadoop Distributed File System(HDFS)

- Los datos en el clúster de Hadoop son divididos en pequeñas piezas llamadas bloques y distribuidas a través del clúster; de esta manera, las funciones map y reduce pueden ser ejecutadas en pequeños subconjuntos y esto provee de la escalabilidad necesaria para el procesamiento de grandes volúmenes.
- La siguiente figura ejemplifica como los bloques de datos son escritos hacia HDFS. Cada bloque es almacenado tres veces y al menos un bloque se almacena en un diferente rack para lograr redundancia.
- Un tamaño de bloque típico utilizado por HDFS es de 64 MB. Por lo tanto, un archivo de HDFS está segmentado en trozos de 64 MB, y tal vez, cada trozo va a residir en un DataNode diferente.



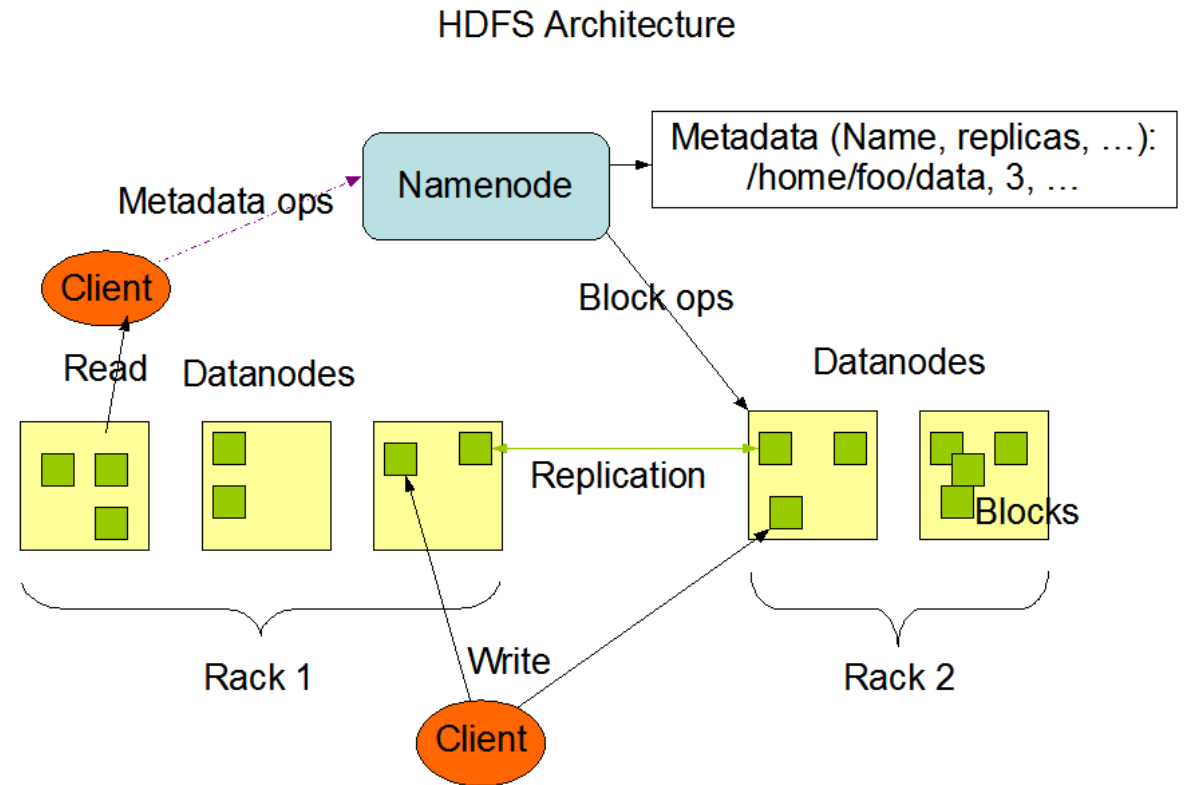


## La replicación de datos

- HDFS está diseñado para almacenar de forma fiable archivos muy grandes a través de las máquinas en un cluster grande.
- Almacena cada archivo como una secuencia de bloques; Todos los bloques de un archivo, excepto el último bloque son del mismo tamaño. Los bloques de un archivo se replican para tolerancia a fallos. El tamaño del bloque y el factor de replicación son configurables por archivo. Una aplicación puede especificar el número de réplicas de un archivo. El factor de replicación se puede especificar en el momento de creación de archivos y se puede cambiar posteriormente.

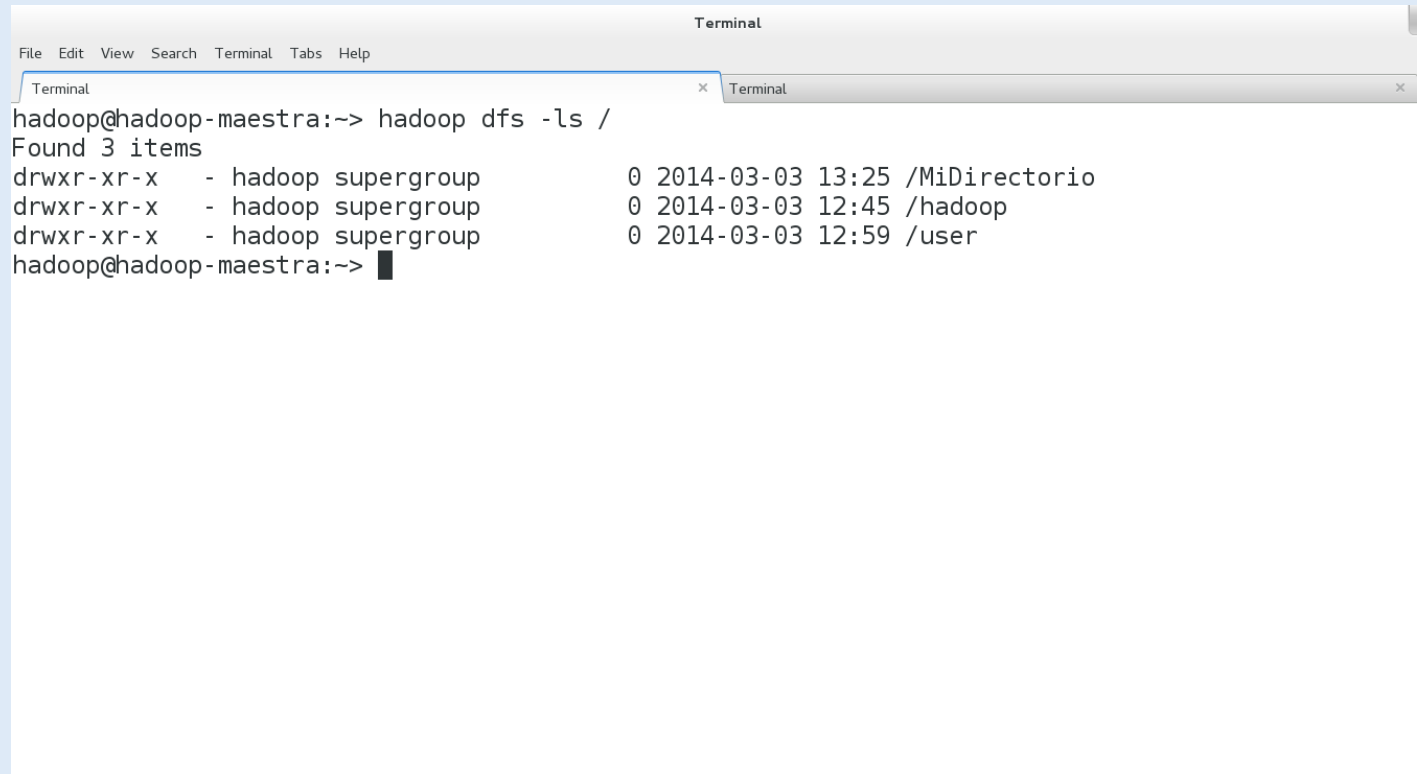
# NameNode y DataNodes

- HDFS tiene una arquitectura maestro / esclavo.
- Un clúster HDFS consta de una solo Nodo de Nombres (NameNode) o servidor maestro que gestiona el espacio de nombres del sistema de archivos y que regula el acceso a los archivos.
- Además, puede constar de una serie de Nodos de Datos (DataNodes), donde se almacenan los archivos y llevan a cabo los procesamientoos.
- Internamente, un archivo se divide en uno o más bloques y estos bloques se almacenan en un conjunto de DataNodes. Los DataNodes también llevan a cabo la creación de bloques, eliminación, y la replicación según las instrucciones del NameNode o máquina maestra.
- El NameNode ejecuta operaciones de espacio de nombres del sistema de archivos como abrir, cerrar y cambiar el nombre de archivos y directorios, los cuales se ejecutan en los nodos de datos





# El espacio de nombres de archivos del HDFS


A screenshot of a terminal window titled "Terminal" with a menu bar (File, Edit, View, Search, Terminal, Tabs, Help). The terminal shows the command "hadoop dfs -ls /" being executed. The output indicates "Found 3 items" and lists three entries: "/MiDirectorio", "/hadoop", and "/user", each with permissions, owner, group, size, modification time, and path.

```
hadoop@hadoop-maestra:~> hadoop dfs -ls /  
Found 3 items  
drwxr-xr-x - hadoop supergroup 0 2014-03-03 13:25 /MiDirectorio  
drwxr-xr-x - hadoop supergroup 0 2014-03-03 12:45 /hadoop  
drwxr-xr-x - hadoop supergroup 0 2014-03-03 12:59 /user  
hadoop@hadoop-maestra:~>
```

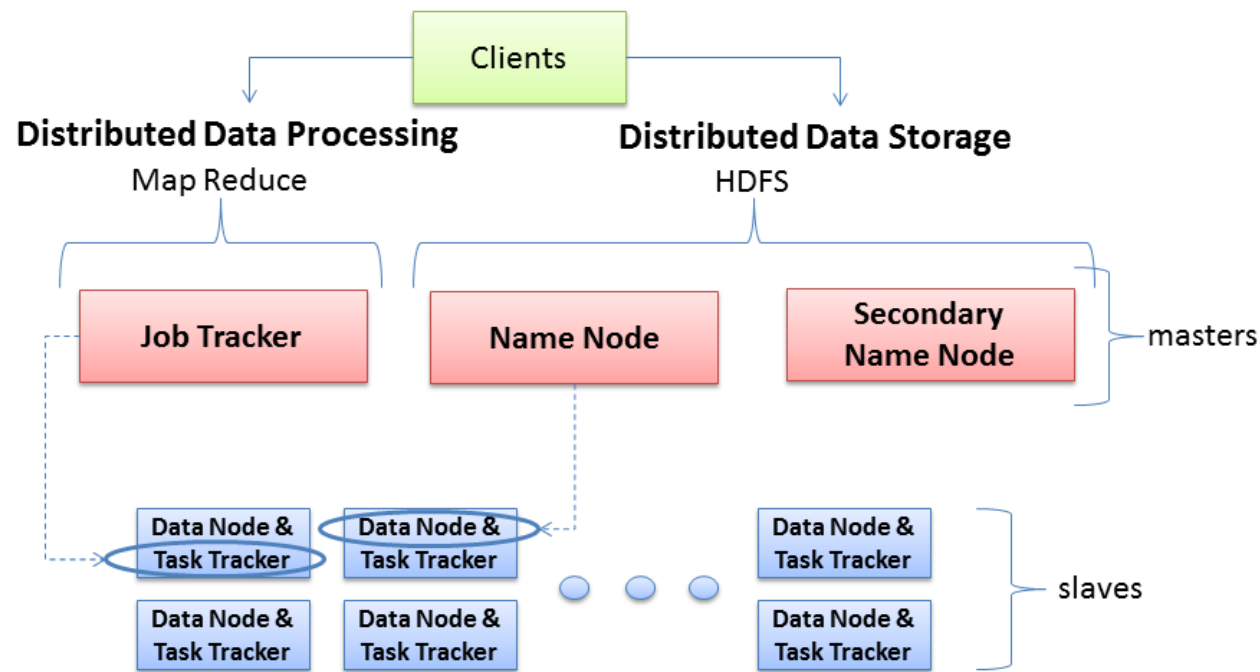
- HDFS ofrece una organización de archivos jerárquico tradicional.
- Un usuario o una aplicación pueden crear directorios y archivos de almacenamiento dentro de estos directorios.
- La jerarquía del espacio de nombres del sistema de archivos es similar a la mayoría de los otros sistemas de archivos existentes; uno puede crear y eliminar archivos, mover un archivo de un directorio a otro, o cambiar el nombre de un archivo.

# Hadoop MapReduce

- **MapReduce** es el núcleo de Hadoop. El término MapReduce en realidad se refiere a dos procesos separados que Hadoop ejecuta.
- El primer proceso es **map**, el cual toma un conjunto de datos y lo convierte en otro conjunto, donde los elementos individuales son separados en tuplas (pares de llave/valor).
- El proceso **reduce** obtiene la salida de **map** como datos de entrada y combina las tuplas en un conjunto más pequeño de las mismas.
- Una fase intermedia es la denominada **Shuffle** la cual obtiene las tuplas del proceso **map** y determina que nodo procesará estos datos dirigiendo la salida a una tarea **reduce** en específico.



# Job Tracker




- El marco de referencia MapReduce consta de una solo monitor de trabajo JobTracker maestro y multiples monitores de tareas una nodo esclavo TaskTracker. El maestro es el responsable de la programación de tareas, se compone de puestos de trabajo en los nodos de datos o esclavos, el seguimiento de ellos y la re-ejecución las tareas fallidas. Los esclavos ejecutan las tareas según las instrucciones del maestro.

# Ejemplo WordCount

- Ejemplo de aplicación del marco de referencia MapReduce para generación de un análisis de frecuencia de palabras en un texto (WordCount)
- WordCount es una sencilla aplicación que cuenta el número de apariciones de cada palabra en un conjunto de datos de entrada. Es decir, se realiza un análisis de frecuencia de cada palabra en el texto.

## Map/Reduce



## The Overall MapReduce Word Count Process

